

Material suplementario

Descriptor multivista de activaciones neuronales, mediante la fusión de grafos funcionales y homología persistente

César Daniel Reinoso Reinoso
Amalia Isabel Escudero Villa

Escuela Superior Politécnica de Chimborazo (ESPOCH), Riobamba, Ecuador

Septiembre de 2026

Repositorio: <https://github.com/Dcrr1717/multiview-nn-descriptor>

Propósito

Este documento acompaña al artículo enviado a la *Revista Bases de la Ciencia* y reúne el material que, por el límite de extensión de la revista, se remitió al repositorio: los enunciados y las demostraciones de las propiedades matemáticas de los descriptores (sección 2), el estudio de solapamiento entre las dos vistas (sección 3), el barrido de sensibilidad sobre el umbral θ y los demás parámetros fijados a priori (sección 4) y las tablas completas de resultados por dominio y por contexto de análisis (sección 5). Todos los valores proceden de los archivos de resultados del repositorio (outputs/) y se escriben con coma decimal, como en el artículo.

1. Notación

Sea $A \in \mathbb{R}^{N \times d}$ la matriz de activaciones de una capa oculta, con N ejemplos de evaluación en las filas y d neuronas en las columnas. La vista de grafo funcional $\mathbf{X}_1 \in \mathbb{R}^{10}$ se obtiene de la matriz de correlaciones de Pearson C entre las primeras $m = \min(d, 80)$ neuronas, umbralizada con $E_{ij} = \mathbf{1}[|C_{ij}| > \theta]$, $\theta = 0,4$, y resumida mediante diez medidas de grafo,

$$\mathbf{X}_1 = [\rho, \bar{C}, \mathcal{T}, \bar{k}, \sigma_k, k_{\max}/|V|, n_{cc}/|V|, |E|/|V|, \bar{c}_B, \sigma_{c_B}]^T, \quad (1)$$

es decir, densidad, agrupamiento medio, transitividad, media, desviación típica y máximo normalizado del grado, fracción de componentes conexas, razón aristas/nodos y media y desviación típica de la centralidad de intermediación. La vista de homología persistente $\mathbf{X}_2 \in \mathbb{R}^{12}$ trata las filas de A : 50], reducidas por PCA a $r = \min(15, d, N - 1)$ componentes y reescaladas a $[0, 1]$, como una nube de puntos P , construye la filtración de Vietoris–Rips $\{\mathcal{VR}(P, \epsilon)\}_{\epsilon \geq 0}$ y resume cada diagrama de persistencia $\text{Dgm}_k(P) = \{(b_j^k, d_j^k)\}_j$, $k \in \{0, 1\}$, con persistencias $p_j^k = d_j^k - b_j^k$, mediante seis estadísticos,

$$\sigma_6(\text{Dgm}_k) = [\bar{p}_k, \text{std}(p_k), \max(p_k), \sum p_k, |\text{Dgm}_k|, P_{75}(p_k)], \quad \mathbf{X}_2 = [\sigma_6(\text{Dgm}_0), \sigma_6(\text{Dgm}_1)]. \quad (2)$$

La variante de control del descriptor fusionado, $\mathbf{X}_3^{(c)} \in \mathbb{R}^{22}$, concatena $\mathbf{X}_1$ y $\mathbf{X}_2$ divididas por su norma euclídea en cada red; la variante adaptativa $\mathbf{X}_3^{(a)} \in \mathbb{R}^{24}$ añade la ponderación por correlación con la exactitud y las dos predicciones Ridge descritas en el artículo.

2. Propiedades matemáticas de los descriptores

Proposición 1 (Invariancia por permutación). *Sea $\pi \in S_d$ una permutación cualquiera de las columnas de A y sea A^π la matriz permutada. Restringido a las mismas $m = \min(d, 80)$ neuronas,*

$\mathbf{X}_1(A^{\pi}_{\cdot, \pi(1..m)}) = \mathbf{X}_1(A_{\cdot, 1..m})$, de modo que reetiquetar las neuronas deja invariante el descriptor de grafo. Lo mismo vale para $\mathbf{X}_2$.

Demostración. La matriz de correlaciones de A^π es $C^\pi = P^\top C P$, donde P es la matriz de permutación asociada a π ; la umbralización componente a componente conmuta con la conjugación por P , de modo que el grafo $G_\theta(A^\pi)$ es isomorfo a $G_\theta(A)$ mediante π . Las diez componentes de (1) (densidad, agrupamiento medio, transitividad, momentos del grado, fracción de componentes conexas, razón aristas/nodos y momentos de la centralidad de intermediación) son invariantes de grafo, es decir, toman el mismo valor sobre grafos isomorfos, pues se definen mediante conteos y promedios sobre vértices y aristas sin referencia al etiquetado. Para $\mathbf{X}_2$, la nube de puntos $\{a_i\} \subset \mathbb{R}^m$ es un conjunto no ordenado y la filtración de Vietoris–Rips depende solo de las distancias entre puntos, que no cambian al reordenar las coordenadas, pues una permutación de coordenadas es una isometría de $\mathbb{R}^m$ con la métrica euclídea. $\square$

Observación 1 (Alcance de la invariancia bajo truncamiento). La invariancia exacta requiere $d \leq 80$, debido a que las capas más anchas se truncan a sus primeras 80 columnas por índice, regla que depende del orden y restringe la garantía a la subpoblación seleccionada. Como el orden de neuronas empleado es fijo y reproducible, la selección de las primeras 80 columnas es idéntica para todas las redes, de modo que la comparación entre descriptores no se ve afectada.

Proposición 2 (Homología de grado cero mediante componentes conexas). *Sea $P = \{p_1, \dots, p_m\}$ una nube finita y sea $G_\epsilon = (P, \{ \{p_i, p_j\} : \|p_i - p_j\|_2 \leq \epsilon \})$ su grafo de vecindad a escala ϵ . Entonces $\beta_0(\mathcal{VR}(P, \epsilon)) = \beta_0(G_\epsilon)$; en particular, el número de clases de grado cero vivas a escala ϵ es igual al número de componentes conexas de G_ϵ , y Dgm_0 queda determinado por los valores de ϵ en los que dos componentes se fusionan.*

Demostración. El grafo G_ϵ es exactamente el 1-esqueleto de $\mathcal{VR}(P, \epsilon)$. La homología en dimensión cero de un complejo simplicial depende solo de su 1-esqueleto, pues H_0 se define como el cociente Z_0/B_0 y los bordes B_0 están generados por las aristas; dos vértices son homólogos si y solo si están unidos por un camino de aristas. Por tanto, las clases de $H_0(\mathcal{VR}(P, \epsilon))$ están en biyección con las componentes conexas de G_ϵ . Al crecer ϵ , cada clase nace en $\epsilon = 0$ (todo punto es una componente) y muere en el menor ϵ en el que su componente se fusiona con otra más antigua; esos valores de fusión son las muertes registradas en Dgm_0 . $\square$

Los diagramas completos son estables respecto de la distancia *cuello de botella* $d_B(D, D') = \inf_\gamma \sup_{x \in D} \|x - \gamma(x)\|_\infty$, con γ recorriendo las biyecciones que emparejan puntos, incluso contra la diagonal.

Teorema 1 (Estabilidad de los diagramas de persistencia; Cohen-Steiner et al., 2007, forma para Vietoris–Rips en Chazal et al., 2014). *Sean $P, Q \subset \mathbb{R}^r$ nubes de puntos finitas y sea $d_H(P, Q)$ su distancia de Hausdorff. Entonces, para toda dimensión k ,*

$$d_B(\text{Dgm}_k(P), \text{Dgm}_k(Q)) \leq 2 d_H(P, Q).$$

Corolario 1. *La persistencia máxima $\max_j p_j^k$ es estable, de modo que si $d_H(P, Q) \leq \delta$, entonces $|\max_j p_j^k(P) - \max_j p_j^k(Q)| \leq 4\delta$.*

Demostración. Sea γ una biyección que realiza $d_B \leq 2\delta$. El punto $x = (b, d)$ que alcanza la persistencia máxima en $\text{Dgm}_k(P)$ se empareja con $\gamma(x) = (b', d')$ en $\text{Dgm}_k(Q)$ (o con la diagonal) con $|b - b'| \leq 2\delta$ y $|d - d'| \leq 2\delta$, de donde la persistencia de $\gamma(x)$ difiere de la de x en a lo sumo 4δ ; como el máximo en Q domina la persistencia de $\gamma(x)$, se sigue $\max p^k(Q) \geq \max p^k(P) - 4\delta$, y por simetría se obtiene la otra desigualdad. $\square$

Observación 2 (Estadísticos fuera de la garantía y variante de respaldo). Dos estadísticos de (2), el conteo $|\text{Dgm}_k|$ y la persistencia total, cambian abruptamente cuando un rasgo de vida corta aparece o desaparece, por lo que quedan fuera de esta garantía; su estabilidad se comprobó empíricamente

con el repertorio replicado del artículo (AUC familiar de 0,929 con 20 arquitecturas reentrenadas con otras semillas). Como alternativa cuando Ripser no está disponible, una variante $\mathbf{X}_2^*$ basada en la Proposición 2 recorre 30 escalas equiespaciadas y recupera Dgm_0 hasta la resolución del muestreo de escalas, con los rasgos de grado uno fijados en cero. Todos los resultados principales del artículo usan el descriptor $\mathbf{X}_2$ completo basado en Ripser; el barrido de la sección 4 usa la variante $\mathbf{X}_2^*$ (véase la nota de esa sección).

3. Solapamiento entre las vistas

Proposición 3 (Solapamiento parcial entre las vistas (empírico)). *En los $n=40$ modelos del repertorio de CIFAR-10, la correlación de Spearman entre pares de rasgos de $\mathbf{X}_1$ y $\mathbf{X}_2$ presenta una mediana de $|\rho|=0,235$, un rango intercuartílico de $[0,11; 0,47]$ y un máximo de 0,829 ($p=4,0 \times 10^{-11}$); tras la corrección de Benjamini–Hochberg ($q \leq 0,05$), 41 de los 110 pares evaluables muestran una asociación significativa.*

Los 110 pares evaluables resultan de cruzar los diez rasgos de $\mathbf{X}_1$ con los doce de $\mathbf{X}_2$, descontados aquellos en que algún rasgo es constante (en CIFAR-10 y SVHN el número de clases de grado cero es constante, por lo que sus diez pares no se evalúan; en CIFAR-100 los 120 pares son evaluables). La Tabla 1 extiende el resumen a los tres dominios y la Figura 1 muestra las tres matrices completas. Ambas vistas comparten información parcial, esperable al derivar de las mismas activaciones, aunque la mayoría de los pares presenta asociación débil ($|\rho| < 0,3$ en más de la mitad de los pares en los tres dominios); si las vistas fueran redundantes, la fusión no superaría a la mejor de ellas, extremo que el artículo descarta en los tres dominios.

Tabla 1: Solapamiento entre las vistas X_1 y X_2 por dominio. Correlación de Spearman entre cada par de rasgos sobre las $n=40$ redes; los pares con algún rasgo constante no son evaluables.

Dominio	Pares	Mediana $ \rho $	RIC	Máx. $ \rho $	Signif. BH ($q \leq 0,05$)	$ \rho < 0,3$	$ \rho > 0,6$
CIFAR-10	110	0,235	[0,11; 0,47]	0,829	41 (37,3 %)	55,5 %	9,1 %
CIFAR-100	120	0,271	[0,14; 0,36]	0,696	22 (18,3 %)	65,8 %	6,7 %
SVHN	110	0,239	[0,12; 0,39]	0,548	33 (30,0 %)	55,5 %	0,0 %




Figura 1: Valor absoluto de la correlaci3n de Spearman entre cada rasgo de X_1 (filas) y de X_2 (columnas) en los tres dominios. Los recuadros negros y las cifras en negrita marcan los pares significativos tras Benjamini–Hochberg ($q \leq 0,05$); el guion marca los pares no evaluables. Datos: `outputs/redundancia_vistas/matriz_redundancia_10x12.json`.

4. Barrido de sensibilidad

El umbral $\theta=0,4$, el tipo de correlaci3n, el tope de 80 neuronas, el n3mero $N=50$ de ejemplos para la homolog3a y el rango $r=15$ de la PCA se fijaron a priori. Para medir cu3nto dependen los resultados de esas elecciones se recalcularon los descriptores de las 40 redes de CIFAR-10 variando un par3metro cada vez (Tabla 2). El barrido se ejecut3 con el guion `phase17_experiments.py` sobre las activaciones re-extra3das de la 3ltima capa oculta (`outputs/fase16_cifar10_raw`), con la fusi3n de pesos iguales y con la variante de respaldo $\mathbf{X}_2^*$ (grado cero por componentes conexas sobre la distancia de correlaci3n, sin Ripser); por ello sus valores absolutos son inferiores al 0,949 del art3culo y no deben compararse con 3l. Lo que interesa del barrido es la amplitud: el umbral θ mueve el AUC familiar en 0,030 dentro de $\{0,2; \dots; 0,6\}$, y el valor adoptado de 0,4 no es el mejor del rango, lo que confirma que no se eligi3 para favorecer al m3todo; el n3mero de ejemplos y el rango de la PCA no alteran el resultado; el tope de neuronas es el par3metro m3s sensible (amplitud 0,059) y la capa analizada tambi3n influye, con mejor separaci3n en la primera capa oculta.

Tabla 2: Barrido de sensibilidad del AUC familiar de X_3 en CIFAR-10 ($n=40$; validación cruzada estratificada de cinco particiones repetida 60 veces, regresión logística uno contra el resto). Referencia: $\theta=0,4$, correlación de Pearson, tope de 80 neuronas, $N=50$ ejemplos, $r=15$ componentes.

Parámetro	Valores	AUC familiar
Umbral θ	0,2	0,871
	0,3	0,871
	0,4 (referencia)	0,862
	0,5	0,841
	0,6	0,856
Tipo de correlación	Pearson (referencia)	0,862
	Spearman	0,832
Tope de neuronas	40	0,812
	80 (referencia)	0,862
	200	0,871
Ejemplos N para la homología	50 (referencia)	0,862
	100	0,862
	200	0,862
Componentes PCA r	8	0,862
	12	0,862
	15 (referencia)	0,862
Capa analizada (redes con ≥ 3 capas, $n=29$)	primera (relu_1)	0,891
	intermedia (relu_4)	0,869
	última (relu_7)	0,819

5. Tablas completas por dominio

Para cada dominio se reportan los cuatro contextos de análisis del artículo (población completa, solo perceptrones multicapa, solo redes convolucionales y exactitud normalizada por tipo de red) y los cinco descriptores evaluados, incluida la variante adaptativa con ponderación por rangos $X_3^{(r)}$, que no se discute en el artículo. Todos los componentes que dependen de la exactitud se reajustaron dentro de cada partición de entrenamiento (sin fuga de información). Fuente: `outputs/fase11_results`, `fase12_results` y `fase13_results/summary_leakfree.json`. La marca n.d.* señala un d de Cohen no definido: en el subconjunto de diez redes convolucionales una de las familias extremas tiene varianza prácticamente nula en la exactitud, de modo que el cociente se dispara sin significado; en ese contexto se reportan solo el AUC y las pruebas de rangos.

CIFAR-10

Rango de exactitud de prueba en el dominio: 42,8 puntos porcentuales en total (11,8 entre perceptrones multicapa y 20,7 entre redes convolucionales).

Tabla 3: CIFAR-10, Población completa ($n=40$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 10/10 (Bonferroni: 10).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,854 [0,81; 0,89]	0,734 [0,55; 0,87]	0,442 [0,37; 0,51]	<0,0001	2,17 [1,21; 4,28]	0,90	0,0008
X_2 (homología persistente)	0,869 [0,83; 0,92]	0,656 [0,47; 0,84]	0,316 [0,27; 0,37]	0,0045	2,49 [1,63; 4,90]	0,90	0,0008
$X_3^{(c)}$ (pesos iguales)	0,949 [0,92; 0,97]	0,755 [0,55; 0,91]	0,522 [0,46; 0,58]	<0,0001	3,34 [2,34; 5,89]	0,98	0,0002
$X_3^{(a)}$ (adaptativa)	0,948 [0,91; 0,98]	0,731 [0,58; 0,89]	0,444 [0,36; 0,50]	0,0003	2,44 [1,30; 4,84]	0,90	0,0008
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,948 [0,91; 0,98]	0,733 [0,55; 0,89]	0,444 [0,36; 0,50]	0,0003	2,44 [1,41; 4,88]	0,90	0,0008

Tabla 4: CIFAR-10, Solo perceptrones multicapa ($n=30$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 10/10 (Bonferroni: 7).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,810 [0,75; 0,86]	0,727 [0,55; 0,87]	0,430 [0,28; 0,54]	<0,0001	2,15 [1,61; 4,53]	1,00	0,0006
X_2 (homología persistente)	0,828 [0,77; 0,89]	0,600 [0,37; 0,79]	0,184 [0,05; 0,29]	0,0401	1,22 [0,47; 2,44]	0,80	0,0111
$X_3^{(c)}$ (pesos iguales)	0,898 [0,85; 0,94]	0,728 [0,56; 0,89]	0,491 [0,37; 0,59]	<0,0001	1,82 [0,76; 4,71]	0,76	0,0175
$X_3^{(a)}$ (adaptativa)	0,920 [0,88; 0,97]	0,714 [0,54; 0,87]	0,441 [0,28; 0,57]	<0,0001	1,99 [1,24; 3,46]	0,92	0,0023
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,920 [0,88; 0,97]	0,711 [0,51; 0,89]	0,441 [0,28; 0,57]	<0,0001	1,99 [1,31; 3,65]	0,92	0,0023

Tabla 5: CIFAR-10, Solo redes convolucionales ($n=10$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 0/10 (Bonferroni: 0).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	1,000 [1,00; 1,00]	0,806 [0,43; 1,00]	0,576 [0,29; 0,78]	0,0167	n. d. *	0,00	1,0000
X_2 (homología persistente)	0,947 [0,71; 1,00]	0,695 [0,20; 1,00]	0,284 [−0,16; 0,58]	0,0466	n. d. *	1,00	0,3333
$X_3^{(c)}$ (pesos iguales)	0,986 [0,83; 1,00]	0,693 [0,00; 1,00]	0,344 [0,07; 0,56]	0,1557	n. d. *	1,00	0,3333
$X_3^{(a)}$ (adaptativa)	0,993 [0,96; 1,00]	0,834 [0,36; 1,00]	0,551 [0,31; 0,71]	0,0167	n. d. *	1,00	0,3333
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,993 [0,96; 1,00]	0,825 [0,40; 1,00]	0,556 [0,31; 0,71]	0,0091	n. d. *	1,00	0,3333

Tabla 6: CIFAR-10, Exactitud normalizada por tipo de red (Y_{norm}). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 9/10 (Bonferroni: 8).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,854 [0,81; 0,89]	0,751 [0,58; 0,86]	0,458 [0,40; 0,51]	<0,0001	2,91 [2,39; 4,63]	1,00	0,0002
X_2 (homología persistente)	0,869 [0,83; 0,92]	0,624 [0,46; 0,79]	0,064 [−0,12; 0,21]	0,4700	1,31 [0,83; 2,11]	0,72	0,0073
$X_3^{(c)}$ (pesos iguales)	0,949 [0,92; 0,97]	0,704 [0,54; 0,83]	0,375 [0,29; 0,46]	<0,0001	3,52 [2,72; 5,85]	1,00	0,0002
$X_3^{(a)}$ (adaptativa)	0,947 [0,91; 0,98]	0,754 [0,60; 0,87]	0,504 [0,42; 0,58]	<0,0001	3,35 [2,55; 5,33]	1,00	0,0002
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,947 [0,91; 0,98]	0,766 [0,64; 0,88]	0,504 [0,42; 0,58]	<0,0001	3,35 [2,59; 5,51]	1,00	0,0002

CIFAR-100

Rango de exactitud de prueba en el dominio: 60,0 puntos porcentuales en total (26,8 entre perceptrones multicapa y 35,5 entre redes convolucionales).

Tabla 7: CIFAR-100, Población completa ($n=40$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 9/10 (Bonferroni: 8).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,778 [0,73; 0,82]	0,588 [0,40; 0,75]	0,129 [−0,01; 0,25]	0,0370	0,56 [−0,30; 1,38]	0,30	0,2730
X_2 (homología persistente)	0,870 [0,84; 0,90]	0,757 [0,59; 0,88]	0,509 [0,42; 0,57]	<0,0001	1,90 [1,16; 3,39]	0,86	0,0013
$X_3^{(c)}$ (pesos iguales)	0,957 [0,93; 0,98]	0,734 [0,52; 0,88]	0,524 [0,40; 0,60]	<0,0001	2,29 [1,56; 3,84]	0,88	0,0010
$X_3^{(a)}$ (adaptativa)	0,943 [0,91; 0,97]	0,721 [0,52; 0,87]	0,493 [0,43; 0,55]	<0,0001	1,76 [1,07; 2,90]	0,86	0,0013
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,943 [0,91; 0,97]	0,718 [0,54; 0,86]	0,493 [0,43; 0,55]	<0,0001	1,76 [1,10; 2,96]	0,86	0,0013

Tabla 8: CIFAR-100, Solo perceptrones multicapa ($n=30$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 8/10 (Bonferroni: 5).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,722 [0,62; 0,79]	0,670 [0,43; 0,89]	0,216 [0,02; 0,37]	0,1083	0,56 [−0,40; 1,48]	0,39	0,2593
X_2 (homología persistente)	0,864 [0,82; 0,90]	0,689 [0,44; 0,89]	0,357 [0,22; 0,46]	0,0008	1,44 [0,70; 2,90]	0,76	0,0175
$X_3^{(c)}$ (pesos iguales)	0,963 [0,93; 0,99]	0,790 [0,63; 0,91]	0,611 [0,49; 0,68]	<0,0001	2,74 [1,72; 6,32]	1,00	0,0006
$X_3^{(a)}$ (adaptativa)	0,949 [0,90; 0,99]	0,721 [0,49; 0,92]	0,442 [0,32; 0,55]	0,0008	0,88 [0,59; 2,36]	0,76	0,0175
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,949 [0,90; 0,99]	0,708 [0,48; 0,92]	0,442 [0,32; 0,55]	0,0008	0,88 [0,56; 1,95]	0,76	0,0175

Tabla 9: CIFAR-100, Solo redes convolucionales ($n=10$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 5/10 (Bonferroni: 5).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	1,000 [1,00; 1,00]	0,891 [0,60; 1,00]	0,669 [0,42; 0,85]	0,0009	n. d. *	1,00	0,3333
X_2 (homología persistente)	0,999 [1,00; 1,00]	0,908 [0,67; 1,00]	0,776 [0,42; 0,89]	0,0009	n. d. *	1,00	0,3333
$X_3^{(c)}$ (pesos iguales)	0,893 [0,62; 1,00]	0,925 [0,38; 1,00]	0,821 [0,44; 0,96]	<0,0001	n. d. *	1,00	0,3333
$X_3^{(a)}$ (adaptativa)	1,000 [1,00; 1,00]	0,901 [0,50; 1,00]	0,777 [0,64; 0,87]	0,0004	n. d. *	1,00	0,3333
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	1,000 [1,00; 1,00]	0,910 [0,55; 1,00]	0,777 [0,64; 0,87]	0,0004	n. d. *	1,00	0,3333

Tabla 10: CIFAR-100, Exactitud normalizada por tipo de red (Y_{norm}). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 9/10 (Bonferroni: 8).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,778 [0,73; 0,82]	0,706 [0,51; 0,88]	0,288 [0,17; 0,44]	0,0001	0,53 [0,13; 1,66]	0,44	0,1041
X_2 (homología persistente)	0,870 [0,84; 0,90]	0,666 [0,48; 0,84]	0,367 [0,21; 0,46]	0,0019	0,99 [0,54; 2,18]	0,64	0,0173
$X_3^{(c)}$ (pesos iguales)	0,957 [0,93; 0,98]	0,772 [0,62; 0,90]	0,549 [0,47; 0,61]	<0,0001	1,26 [0,26; 3,85]	0,78	0,0036
$X_3^{(a)}$ (adaptativa)	0,948 [0,91; 0,98]	0,732 [0,48; 0,89]	0,504 [0,37; 0,60]	<0,0001	0,85 [0,64; 2,36]	0,80	0,0028
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,948 [0,91; 0,98]	0,745 [0,55; 0,94]	0,504 [0,37; 0,60]	<0,0001	0,85 [0,65; 2,33]	0,80	0,0028

SVHN

Rango de exactitud de prueba en el dominio: 26,0 puntos porcentuales en total (16,5 entre perceptrones multicapa y 7,2 entre redes convolucionales).

Tabla 11: SVHN, Población completa ($n=40$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 10/10 (Bonferroni: 10).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,928 [0,89; 0,95]	0,745 [0,60; 0,87]	0,470 [0,41; 0,54]	<0,0001	1,68 [0,55; 5,51]	0,80	0,0028
X_2 (homología persistente)	0,913 [0,88; 0,94]	0,747 [0,58; 0,87]	0,507 [0,44; 0,57]	<0,0001	2,31 [1,40; 4,02]	0,86	0,0013
$X_3^{(c)}$ (pesos iguales)	0,972 [0,94; 1,00]	0,762 [0,62; 0,88]	0,470 [0,40; 0,55]	<0,0001	0,71 [−0,19; 3,76]	0,80	0,0028
$X_3^{(a)}$ (adaptativa)	0,965 [0,94; 0,99]	0,803 [0,68; 0,91]	0,611 [0,53; 0,66]	<0,0001	3,86 [2,83; 6,40]	1,00	0,0002
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,965 [0,94; 0,99]	0,795 [0,66; 0,90]	0,611 [0,53; 0,66]	<0,0001	3,86 [2,83; 6,20]	1,00	0,0002

Tabla 12: SVHN, Solo perceptrones multicapa ($n=30$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 8/10 (Bonferroni: 4).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,875 [0,80; 0,93]	0,633 [0,39; 0,85]	0,188 [−0,03; 0,36]	0,4788	1,04 [0,00; 2,79]	0,63	0,0530
X_2 (homología persistente)	0,873 [0,82; 0,93]	0,724 [0,56; 0,86]	0,389 [0,29; 0,48]	0,0067	2,47 [1,61; 5,36]	0,92	0,0023
$X_3^{(c)}$ (pesos iguales)	0,958 [0,91; 0,99]	0,666 [0,44; 0,87]	0,345 [0,11; 0,48]	0,0003	1,39 [0,55; 2,94]	0,71	0,0262
$X_3^{(a)}$ (adaptativa)	0,938 [0,90; 0,97]	0,679 [0,44; 0,88]	0,413 [0,25; 0,54]	0,0003	1,54 [0,73; 3,08]	0,76	0,0175
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,938 [0,90; 0,97]	0,686 [0,46; 0,89]	0,413 [0,25; 0,54]	0,0003	1,54 [0,82; 3,13]	0,76	0,0175

Tabla 13: SVHN, Solo redes convolucionales ($n=10$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 0/10 (Bonferroni: 0).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	1,000 [1,00; 1,00]	0,785 [0,33; 1,00]	0,491 [0,18; 0,69]	0,0286	n. d. *	0,00	1,0000
X_2 (homología persistente)	1,000 [1,00; 1,00]	0,720 [0,32; 1,00]	0,284 [−0,09; 0,53]	0,2164	n. d. *	0,50	0,6667
$X_3^{(c)}$ (pesos iguales)	0,981 [0,83; 1,00]	0,792 [0,33; 1,00]	0,440 [0,11; 0,65]	0,0726	n. d. *	1,00	0,3333
$X_3^{(a)}$ (adaptativa)	1,000 [1,00; 1,00]	0,763 [0,33; 1,00]	0,425 [−0,00; 0,64]	0,0466	n. d. *	1,00	0,3333
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	1,000 [1,00; 1,00]	0,755 [0,33; 1,00]	0,425 [−0,00; 0,64]	0,0466	n. d. *	1,00	0,3333

Tabla 14: SVHN, Exactitud normalizada por tipo de red (Y_{norm}). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 8/10 (Bonferroni: 6).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,928 [0,89; 0,95]	0,642 [0,47; 0,81]	0,012 [−0,19; 0,19]	0,2838	0,59 [−0,27; 1,86]	0,36	0,1859
X_2 (homología persistente)	0,913 [0,88; 0,94]	0,718 [0,54; 0,85]	0,371 [0,27; 0,46]	0,0002	1,59 [0,74; 3,06]	0,74	0,0058
$X_3^{(c)}$ (pesos iguales)	0,972 [0,94; 1,00]	0,667 [0,48; 0,84]	0,373 [0,26; 0,48]	0,0064	1,35 [0,39; 3,34]	0,80	0,0028
$X_3^{(a)}$ (adaptativa)	0,963 [0,93; 0,98]	0,683 [0,51; 0,83]	0,401 [0,29; 0,50]	<0,0001	1,46 [0,59; 3,03]	0,78	0,0036
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,963 [0,93; 0,98]	0,686 [0,47; 0,82]	0,401 [0,29; 0,50]	<0,0001	1,46 [0,60; 3,17]	0,78	0,0036

Referencias

- Ballester, R., Arnal Clemente, X., Casacuberta, C., Madadi, M., Corneanu, C. A. y Escalera, S. (2024). Predicting the generalization gap in neural networks using topological data analysis. *Neurocomputing*, 596, 127787.
- Bauer, U. (2021). Ripser: efficient computation of Vietoris–Rips persistence barcodes. *Journal of Applied and Computational Topology*, 5, 391–423.
- Chazal, F., de Silva, V. y Oudot, S. (2014). Persistence stability for geometric complexes. *Geometriae Dedicata*, 173, 193–214.
- Cohen-Steiner, D., Edelsbrunner, H. y Harer, J. (2007). Stability of persistence diagrams. *Discrete & Computational Geometry*, 37, 103–120.
- Edelsbrunner, H., Letscher, D. y Zomorodian, A. (2002). Topological persistence and simplification. *Discrete & Computational Geometry*, 28, 511–533.
- Zhang, B., Dong, Z., Zhang, J. y Lin, H. (2023). Functional network: A novel framework for interpretability of deep neural networks. *Neurocomputing*, 519, 94–103.