

Material suplementario

Descriptor multivista de activaciones neuronales, mediante la fusión de grafos funcionales y homología persistente

César Daniel Reinoso Reinoso
Amalia Isabel Escudero Villa

Escuela Superior Politécnica de Chimborazo (ESPOCH), Riobamba, Ecuador

Septiembre de 2026

Repositorio: <https://github.com/Dcrr1717/multiview-nn-descriptor>

Propósito

Este documento acompaña al artículo enviado a la *Revista Bases de la Ciencia* y reúne el material que, por el límite de extensión de la revista, se remitió al repositorio: los enunciados y las demostraciones de las propiedades matemáticas de los descriptores (sección 2), el estudio de solapamiento entre las dos vistas (sección 3), el barrido de sensibilidad sobre el umbral θ y los demás parámetros fijados a priori (sección 4) y las tablas completas de resultados por dominio y por contexto de análisis (sección 7). Todos los valores proceden de los archivos de resultados del repositorio (outputs/) y se escriben con coma decimal, como en el artículo.

1. Notación

Sea $A \in \mathbb{R}^{N \times d}$ la matriz de activaciones de una capa oculta, con N ejemplos de evaluación en las filas y d neuronas en las columnas. La vista de grafo funcional $\mathbf{X}_1 \in \mathbb{R}^{10}$ se obtiene de la matriz de correlaciones de Pearson C entre las primeras $m = \min(d, 80)$ neuronas, umbralizada con $E_{ij} = \mathbf{1}[|C_{ij}| > \theta]$, $\theta = 0,4$, y resumida mediante diez medidas de grafo,

$$\mathbf{X}_1 = [\rho, \bar{C}, \mathcal{T}, \bar{k}, \sigma_k, k_{\max}/|V|, n_{cc}/|V|, |E|/|V|, \bar{c}_B, \sigma_{c_B}]^T, \quad (1)$$

es decir, densidad, agrupamiento medio, transitividad, media, desviación típica y máximo normalizado del grado, fracción de componentes conexas, razón aristas/nodos y media y desviación típica de la centralidad de intermediación. La vista de homología persistente $\mathbf{X}_2 \in \mathbb{R}^{12}$ trata las filas de A : 50], reducidas por PCA a $r = \min(15, d, N - 1)$ componentes y reescaladas a $[0, 1]$, como una nube de puntos P , construye la filtración de Vietoris–Rips $\{\mathcal{VR}(P, \epsilon)\}_{\epsilon \geq 0}$ y resume cada diagrama de persistencia $\text{Dgm}_k(P) = \{(b_j^k, d_j^k)\}_j$, $k \in \{0, 1\}$, con persistencias $p_j^k = d_j^k - b_j^k$, mediante seis estadísticos,

$$\sigma_6(\text{Dgm}_k) = [\bar{p}_k, \text{std}(p_k), \max(p_k), \sum p_k, |\text{Dgm}_k|, P_{75}(p_k)], \quad \mathbf{X}_2 = [\sigma_6(\text{Dgm}_0), \sigma_6(\text{Dgm}_1)]. \quad (2)$$

La variante de control del descriptor fusionado, $\mathbf{X}_3^{(c)} \in \mathbb{R}^{22}$, concatena $\mathbf{X}_1$ y $\mathbf{X}_2$ divididas por su norma euclídea en cada red; la variante adaptativa $\mathbf{X}_3^{(a)} \in \mathbb{R}^{24}$ añade la ponderación por correlación con la exactitud y las dos predicciones Ridge descritas en el artículo.

2. Propiedades matemáticas de los descriptores

Proposición 1 (Invariancia por permutación). *Sea $\pi \in S_d$ una permutación cualquiera de las columnas de A y sea A^π la matriz permutada. Restringido a las mismas $m = \min(d, 80)$ neuronas,*

$\mathbf{X}_1(A^{\pi}_{\cdot, \pi(1..m)}) = \mathbf{X}_1(A_{\cdot, 1..m})$, de modo que reetiquetar las neuronas deja invariante el descriptor de grafo. Lo mismo vale para $\mathbf{X}_2$.

Demostración. La matriz de correlaciones de A^π es $C^\pi = P^\top C P$, donde P es la matriz de permutación asociada a π ; la umbralización componente a componente conmuta con la conjugación por P , de modo que el grafo $G_\theta(A^\pi)$ es isomorfo a $G_\theta(A)$ mediante π . Las diez componentes de (1) (densidad, agrupamiento medio, transitividad, momentos del grado, fracción de componentes conexas, razón aristas/nodos y momentos de la centralidad de intermediación) son invariantes de grafo, es decir, toman el mismo valor sobre grafos isomorfos, pues se definen mediante conteos y promedios sobre vértices y aristas sin referencia al etiquetado. Para $\mathbf{X}_2$, la nube de puntos $\{a_i\} \subset \mathbb{R}^m$ es un conjunto no ordenado y la filtración de Vietoris–Rips depende solo de las distancias entre puntos, que no cambian al reordenar las coordenadas, pues una permutación de coordenadas es una isometría de $\mathbb{R}^m$ con la métrica euclídea. $\square$

Observación 1 (Alcance de la invariancia bajo truncamiento). La invariancia exacta requiere $d \leq 80$, debido a que las capas más anchas se truncan a sus primeras 80 columnas por índice, regla que depende del orden y restringe la garantía a la subpoblación seleccionada. Como el orden de neuronas empleado es fijo y reproducible, la selección de las primeras 80 columnas es idéntica para todas las redes, de modo que la comparación entre descriptores no se ve afectada.

Proposición 2 (Homología de grado cero mediante componentes conexas). *Sea $P = \{p_1, \dots, p_m\}$ una nube finita y sea $G_\epsilon = (P, \{ \{p_i, p_j\} : \|p_i - p_j\|_2 \leq \epsilon \})$ su grafo de vecindad a escala ϵ . Entonces $\beta_0(\mathcal{VR}(P, \epsilon)) = \beta_0(G_\epsilon)$; en particular, el número de clases de grado cero vivas a escala ϵ es igual al número de componentes conexas de G_ϵ , y Dgm_0 queda determinado por los valores de ϵ en los que dos componentes se fusionan.*

Demostración. El grafo G_ϵ es exactamente el 1-esqueleto de $\mathcal{VR}(P, \epsilon)$. La homología en dimensión cero de un complejo simplicial depende solo de su 1-esqueleto, pues H_0 se define como el cociente Z_0/B_0 y los bordes B_0 están generados por las aristas; dos vértices son homólogos si y solo si están unidos por un camino de aristas. Por tanto, las clases de $H_0(\mathcal{VR}(P, \epsilon))$ están en biyección con las componentes conexas de G_ϵ . Al crecer ϵ , cada clase nace en $\epsilon = 0$ (todo punto es una componente) y muere en el menor ϵ en el que su componente se fusiona con otra más antigua; esos valores de fusión son las muertes registradas en Dgm_0 . $\square$

Los diagramas completos son estables respecto de la distancia *cuello de botella* $d_B(D, D') = \inf_\gamma \sup_{x \in D} \|x - \gamma(x)\|_\infty$, con γ recorriendo las biyecciones que emparejan puntos, incluso contra la diagonal.

Teorema 1 (Estabilidad de los diagramas de persistencia; Cohen-Steiner et al., 2007, forma para Vietoris–Rips en Chazal et al., 2014). *Sean $P, Q \subset \mathbb{R}^r$ nubes de puntos finitas y sea $d_H(P, Q)$ su distancia de Hausdorff. Entonces, para toda dimensión k ,*

$$d_B(\text{Dgm}_k(P), \text{Dgm}_k(Q)) \leq 2 d_H(P, Q).$$

Corolario 1. *La persistencia máxima $\max_j p_j^k$ es estable, de modo que si $d_H(P, Q) \leq \delta$, entonces $|\max_j p_j^k(P) - \max_j p_j^k(Q)| \leq 4\delta$.*

Demostración. Sea γ una biyección que realiza $d_B \leq 2\delta$. El punto $x = (b, d)$ que alcanza la persistencia máxima en $\text{Dgm}_k(P)$ se empareja con $\gamma(x) = (b', d')$ en $\text{Dgm}_k(Q)$ (o con la diagonal) con $|b - b'| \leq 2\delta$ y $|d - d'| \leq 2\delta$, de donde la persistencia de $\gamma(x)$ difiere de la de x en a lo sumo 4δ ; como el máximo en Q domina la persistencia de $\gamma(x)$, se sigue $\max p^k(Q) \geq \max p^k(P) - 4\delta$, y por simetría se obtiene la otra desigualdad. $\square$

Observación 2 (Estadísticos fuera de la garantía y variante de respaldo). Dos estadísticos de (2), el conteo $|\text{Dgm}_k|$ y la persistencia total, cambian abruptamente cuando un rasgo de vida corta aparece o desaparece, por lo que quedan fuera de esta garantía; su estabilidad se comprobó empíricamente

con el repertorio replicado del artículo (AUC familiar de 0,929 con 20 arquitecturas reentrenadas con otras semillas). Como alternativa cuando Ripser no está disponible, una variante $\mathbf{X}_2^*$ basada en la Proposición 2 recorre 30 escalas equiespaciadas y recupera Dgm_0 hasta la resolución del muestreo de escalas, con los rasgos de grado uno fijados en cero. Todos los resultados principales del artículo usan el descriptor $\mathbf{X}_2$ completo basado en Ripser; el barrido de la sección 4 usa la variante $\mathbf{X}_2^*$ (véase la nota de esa sección).

3. Solapamiento entre las vistas

Proposición 3 (Solapamiento parcial entre las vistas (empírico)). *En los $n=40$ modelos del repertorio de CIFAR-10, la correlación de Spearman entre pares de rasgos de $\mathbf{X}_1$ y $\mathbf{X}_2$ presenta una mediana de $|\rho|=0,235$, un rango intercuartílico de $[0,11; 0,47]$ y un máximo de 0,829 ($p=4,0 \times 10^{-11}$); tras la corrección de Benjamini–Hochberg ($q \leq 0,05$), 41 de los 110 pares evaluables muestran una asociación significativa.*

Los 110 pares evaluables resultan de cruzar los diez rasgos de $\mathbf{X}_1$ con los doce de $\mathbf{X}_2$, descontados aquellos en que algún rasgo es constante (en CIFAR-10 y SVHN el número de clases de grado cero es constante, por lo que sus diez pares no se evalúan; en CIFAR-100 los 120 pares son evaluables). La Tabla 1 extiende el resumen a los tres dominios y la Figura 1 muestra las tres matrices completas. Ambas vistas comparten información parcial, esperable al derivar de las mismas activaciones, aunque la mayoría de los pares presenta asociación débil ($|\rho| < 0,3$ en más de la mitad de los pares en los tres dominios); si las vistas fueran redundantes, la fusión no superaría a la mejor de ellas, extremo que el artículo descarta en los tres dominios.

Tabla 1: Solapamiento entre las vistas X_1 y X_2 por dominio. Correlación de Spearman entre cada par de rasgos sobre las $n=40$ redes; los pares con algún rasgo constante no son evaluables.

Dominio	Pares	Mediana $ \rho $	RIC	Máx. $ \rho $	Signif. BH ($q \leq 0,05$)	$ \rho < 0,3$	$ \rho > 0,6$
CIFAR-10	110	0,235	[0,11; 0,47]	0,829	41 (37,3 %)	55,5 %	9,1 %
CIFAR-100	120	0,271	[0,14; 0,36]	0,696	22 (18,3 %)	65,8 %	6,7 %
SVHN	110	0,239	[0,12; 0,39]	0,548	33 (30,0 %)	55,5 %	0,0 %




Figura 1: Valor absoluto de la correlaci3n de Spearman entre cada rasgo de X_1 (filas) y de X_2 (columnas) en los tres dominios. Los recuadros negros y las cifras en negrita marcan los pares significativos tras Benjamini–Hochberg ($q \leq 0,05$); el guion marca los pares no evaluables. Datos: `outputs/redundancia_vistas/matriz_redundancia_10x12.json`.

4. Barrido de sensibilidad

El umbral $\theta=0,4$, el tipo de correlaci3n, el tope de 80 neuronas, el n3mero $N=50$ de ejemplos para la homolog3a y el rango $r=15$ de la PCA se fijaron a priori. Para medir cu3nto dependen los resultados de esas elecciones se recalcularon los descriptores de las 40 redes de CIFAR-10 variando un par3metro cada vez (Tabla 2). El barrido se ejecut3 con el guion `phase17_experiments.py` sobre las activaciones re-extra3das de la 3ltima capa oculta (`outputs/fase16_cifar10_raw`), con la fusi3n de pesos iguales y con la variante de respaldo $\mathbf{X}_2^*$ (grado cero por componentes conexas sobre la distancia de correlaci3n, sin Ripser); por ello sus valores absolutos son inferiores al 0,949 del art3culo y no deben compararse con 3l. Lo que interesa del barrido es la amplitud: el umbral θ mueve el AUC familiar en 0,030 dentro de $\{0,2; \dots; 0,6\}$, y el valor adoptado de 0,4 no es el mejor del rango, lo que confirma que no se eligi3 para favorecer al m3todo; el n3mero de ejemplos y el rango de la PCA no alteran el resultado; el tope de neuronas es el par3metro m3s sensible (amplitud 0,059) y la capa analizada tambi3n influye, con mejor separaci3n en la primera capa oculta.

Tabla 2: Barrido de sensibilidad del AUC familiar de X_3 en CIFAR-10 ($n=40$; validación cruzada estratificada de cinco particiones repetida 60 veces, regresión logística uno contra el resto). Referencia: $\theta=0,4$, correlación de Pearson, tope de 80 neuronas, $N=50$ ejemplos, $r=15$ componentes.

Parámetro	Valores	AUC familiar
Umbral θ	0,2	0,871
	0,3	0,871
	0,4 (referencia)	0,862
	0,5	0,841
	0,6	0,856
Tipo de correlación	Pearson (referencia)	0,862
	Spearman	0,832
Tope de neuronas	40	0,812
	80 (referencia)	0,862
	200	0,871
Ejemplos N para la homología	50 (referencia)	0,862
	100	0,862
	200	0,862
Componentes PCA r	8	0,862
	12	0,862
	15 (referencia)	0,862
Capa analizada (redes con ≥ 3 capas, $n=29$)	primera (<code>relu_1</code>)	0,891
	intermedia (<code>relu_4</code>)	0,869
	última (<code>relu_7</code>)	0,819

5. Comprobaciones de robustez

El artículo resume cuatro comprobaciones adicionales sobre el repertorio de CIFAR-10; sus valores exactos, obtenidos con `phase15_reviewer.py` (registro en `supplement/phase15_robustez.log`), son los siguientes. Primera, estabilidad de la ponderación: la correlación de Spearman entre los pesos $w^{(v)}$ ajustados con toda la muestra y los ajustados dentro de cada pliegue fue, en promedio, de 0,970 en CIFAR-10, 0,956 en CIFAR-100 y 0,934 en SVHN. Segunda, aporte de las dos proyecciones Ridge: la variante adaptativa alcanzó un AUC familiar de 0,947 [0,91; 0,98] con ellas (24 dimensiones) y de 0,943 [0,90; 0,97] sin ellas (22 dimensiones), un aporte de +0,004. Tercera, AUC uno contra el resto por familia para $X_3^{(c)}$: A (ReLU) 0,944; B (BatchNorm y GELU) 0,890; C (residual) 0,963; D (CNN pequeña) 0,999; E (CNN residual) 1,000. Cuarta, línea base de metadatos enriquecida (número de parámetros, su logaritmo, profundidad y anchura): 0,854 [0,81; 0,89] frente a 0,949 [0,92; 0,97] de $X_3^{(c)}$, una ventaja de +0,095. Además, los pesos aprendidos en distintos dominios no se parecen entre sí (Spearman de $-0,04$ a $0,40$ entre pares de dominios), lo que refuerza la elección de la variante de control sin ponderación para los resultados principales.

6. Figuras complementarias

Las cuatro figuras siguientes acompañaban a versiones anteriores del artículo y se remiten aquí por el límite de extensión de la revista; sus cifras aparecen en el texto del artículo.




Figura 2: AUC familiar en los cinco pliegues de validación cruzada (CIFAR-10). Cada punto es un pliegue, los violines son densidades de núcleo y las barras marcan las medianas; el contraste de Wilcoxon unilateral sobre los cinco pliegues pareados arrojó $p=0,031$ para $X_3^{(c)}$ frente a X_1 (*) y $p=0,062$ frente a X_2 (n.s.).




Figura 3: Valores p de la batería de diez pruebas por dominio frente al umbral escalonado de Benjamini–Hochberg (qk/m , $q=0,05$) y a la cota de Bonferroni ($\alpha/m=0,005$): 29 de las 30 pruebas superan la corrección y 28 resisten Bonferroni.




Figura 4: Tamaños de efecto por descriptor y dominio entre los cuartos extremos de exactitud: d de Cohen con IC 95 % bootstrap (izquierda) y $|r|$ de Mann–Whitney (derecha); el relleno marca los contrastes significativos tras Benjamini–Hochberg. $X_3^{(r)}$ es la variante adaptativa con ponderación por rangos (Spearman al cuadrado), que solo interviene en la batería.

7. Tablas completas por dominio

Para cada dominio se reportan los cuatro contextos de análisis del artículo (población completa, solo perceptrones multicapa, solo redes convolucionales y exactitud normalizada por tipo de red) y los cinco descriptores evaluados, incluida la variante adaptativa con ponderación por rangos $X_3^{(r)}$, que no se discute en el artículo. Todos los componentes que dependen de la exactitud se reajustaron dentro de cada partición de entrenamiento (sin fuga de información). Fuente: `outputs/fase11_results`, `fase12_results` y `fase13_results/summary_leakfree.json`. La marca n.d.* señala un d de Cohen no definido: en el subconjunto de diez redes convolucionales una de las familias extremas tiene varianza prácticamente nula en la exactitud, de modo que el cociente se dispara sin significado; en ese contexto se reportan solo el AUC y las pruebas de rangos.

CIFAR-10

Rango de exactitud de prueba en el dominio: 42,8 puntos porcentuales en total (11,8 entre perceptrones multicapa y 20,7 entre redes convolucionales).

Tabla 3: CIFAR-10, Población completa ($n=40$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 10/10 (Bonferroni: 10).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,854 [0,81; 0,89]	0,734 [0,55; 0,87]	0,442 [0,37; 0,51]	<0,0001	2,17 [1,21; 4,28]	0,90	0,0008
X_2 (homología persistente)	0,869 [0,83; 0,92]	0,656 [0,47; 0,84]	0,316 [0,27; 0,37]	0,0045	2,49 [1,63; 4,90]	0,90	0,0008
$X_3^{(c)}$ (pesos iguales)	0,949 [0,92; 0,97]	0,755 [0,55; 0,91]	0,522 [0,46; 0,58]	<0,0001	3,34 [2,34; 5,89]	0,98	0,0002
$X_3^{(a)}$ (adaptativa)	0,948 [0,91; 0,98]	0,731 [0,58; 0,89]	0,444 [0,36; 0,50]	0,0003	2,44 [1,30; 4,84]	0,90	0,0008
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,948 [0,91; 0,98]	0,733 [0,55; 0,89]	0,444 [0,36; 0,50]	0,0003	2,44 [1,41; 4,88]	0,90	0,0008

Tabla 4: CIFAR-10, Solo perceptrones multicapa ($n=30$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 10/10 (Bonferroni: 7).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,810 [0,75; 0,86]	0,727 [0,55; 0,87]	0,430 [0,28; 0,54]	<0,0001	2,15 [1,61; 4,53]	1,00	0,0006
X_2 (homología persistente)	0,828 [0,77; 0,89]	0,600 [0,37; 0,79]	0,184 [0,05; 0,29]	0,0401	1,22 [0,47; 2,44]	0,80	0,0111
$X_3^{(c)}$ (pesos iguales)	0,898 [0,85; 0,94]	0,728 [0,56; 0,89]	0,491 [0,37; 0,59]	<0,0001	1,82 [0,76; 4,71]	0,76	0,0175
$X_3^{(a)}$ (adaptativa)	0,920 [0,88; 0,97]	0,714 [0,54; 0,87]	0,441 [0,28; 0,57]	<0,0001	1,99 [1,24; 3,46]	0,92	0,0023
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,920 [0,88; 0,97]	0,711 [0,51; 0,89]	0,441 [0,28; 0,57]	<0,0001	1,99 [1,31; 3,65]	0,92	0,0023

Tabla 5: CIFAR-10, Solo redes convolucionales ($n=10$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 0/10 (Bonferroni: 0).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	1,000 [1,00; 1,00]	0,806 [0,43; 1,00]	0,576 [0,29; 0,78]	0,0167	n. d. *	0,00	1,0000
X_2 (homología persistente)	0,947 [0,71; 1,00]	0,695 [0,20; 1,00]	0,284 [−0,16; 0,58]	0,0466	n. d. *	1,00	0,3333
$X_3^{(c)}$ (pesos iguales)	0,986 [0,83; 1,00]	0,693 [0,00; 1,00]	0,344 [0,07; 0,56]	0,1557	n. d. *	1,00	0,3333
$X_3^{(a)}$ (adaptativa)	0,993 [0,96; 1,00]	0,834 [0,36; 1,00]	0,551 [0,31; 0,71]	0,0167	n. d. *	1,00	0,3333
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,993 [0,96; 1,00]	0,825 [0,40; 1,00]	0,556 [0,31; 0,71]	0,0091	n. d. *	1,00	0,3333

Tabla 6: CIFAR-10, Exactitud normalizada por tipo de red (Y_{norm}). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 9/10 (Bonferroni: 8).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,854 [0,81; 0,89]	0,751 [0,58; 0,86]	0,458 [0,40; 0,51]	<0,0001	2,91 [2,39; 4,63]	1,00	0,0002
X_2 (homología persistente)	0,869 [0,83; 0,92]	0,624 [0,46; 0,79]	0,064 [−0,12; 0,21]	0,4700	1,31 [0,83; 2,11]	0,72	0,0073
$X_3^{(c)}$ (pesos iguales)	0,949 [0,92; 0,97]	0,704 [0,54; 0,83]	0,375 [0,29; 0,46]	<0,0001	3,52 [2,72; 5,85]	1,00	0,0002
$X_3^{(a)}$ (adaptativa)	0,947 [0,91; 0,98]	0,754 [0,60; 0,87]	0,504 [0,42; 0,58]	<0,0001	3,35 [2,55; 5,33]	1,00	0,0002
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,947 [0,91; 0,98]	0,766 [0,64; 0,88]	0,504 [0,42; 0,58]	<0,0001	3,35 [2,59; 5,51]	1,00	0,0002

CIFAR-100

Rango de exactitud de prueba en el dominio: 60,0 puntos porcentuales en total (26,8 entre perceptrones multicapa y 35,5 entre redes convolucionales).

Tabla 7: CIFAR-100, Población completa ($n=40$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 9/10 (Bonferroni: 8).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,778 [0,73; 0,82]	0,588 [0,40; 0,75]	0,129 [−0,01; 0,25]	0,0370	0,56 [−0,30; 1,38]	0,30	0,2730
X_2 (homología persistente)	0,870 [0,84; 0,90]	0,757 [0,59; 0,88]	0,509 [0,42; 0,57]	<0,0001	1,90 [1,16; 3,39]	0,86	0,0013
$X_3^{(c)}$ (pesos iguales)	0,957 [0,93; 0,98]	0,734 [0,52; 0,88]	0,524 [0,40; 0,60]	<0,0001	2,29 [1,56; 3,84]	0,88	0,0010
$X_3^{(a)}$ (adaptativa)	0,943 [0,91; 0,97]	0,721 [0,52; 0,87]	0,493 [0,43; 0,55]	<0,0001	1,76 [1,07; 2,90]	0,86	0,0013
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,943 [0,91; 0,97]	0,718 [0,54; 0,86]	0,493 [0,43; 0,55]	<0,0001	1,76 [1,10; 2,96]	0,86	0,0013

Tabla 8: CIFAR-100, Solo perceptrones multicapa ($n=30$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 8/10 (Bonferroni: 5).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,722 [0,62; 0,79]	0,670 [0,43; 0,89]	0,216 [0,02; 0,37]	0,1083	0,56 [−0,40; 1,48]	0,39	0,2593
X_2 (homología persistente)	0,864 [0,82; 0,90]	0,689 [0,44; 0,89]	0,357 [0,22; 0,46]	0,0008	1,44 [0,70; 2,90]	0,76	0,0175
$X_3^{(c)}$ (pesos iguales)	0,963 [0,93; 0,99]	0,790 [0,63; 0,91]	0,611 [0,49; 0,68]	<0,0001	2,74 [1,72; 6,32]	1,00	0,0006
$X_3^{(a)}$ (adaptativa)	0,949 [0,90; 0,99]	0,721 [0,49; 0,92]	0,442 [0,32; 0,55]	0,0008	0,88 [0,59; 2,36]	0,76	0,0175
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,949 [0,90; 0,99]	0,708 [0,48; 0,92]	0,442 [0,32; 0,55]	0,0008	0,88 [0,56; 1,95]	0,76	0,0175

Tabla 9: CIFAR-100, Solo redes convolucionales ($n=10$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 5/10 (Bonferroni: 5).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	1,000 [1,00; 1,00]	0,891 [0,60; 1,00]	0,669 [0,42; 0,85]	0,0009	n. d.*	1,00	0,3333
X_2 (homología persistente)	0,999 [1,00; 1,00]	0,908 [0,67; 1,00]	0,776 [0,42; 0,89]	0,0009	n. d.*	1,00	0,3333
$X_3^{(c)}$ (pesos iguales)	0,893 [0,62; 1,00]	0,925 [0,38; 1,00]	0,821 [0,44; 0,96]	<0,0001	n. d.*	1,00	0,3333
$X_3^{(a)}$ (adaptativa)	1,000 [1,00; 1,00]	0,901 [0,50; 1,00]	0,777 [0,64; 0,87]	0,0004	n. d.*	1,00	0,3333
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	1,000 [1,00; 1,00]	0,910 [0,55; 1,00]	0,777 [0,64; 0,87]	0,0004	n. d.*	1,00	0,3333

Tabla 10: CIFAR-100, Exactitud normalizada por tipo de red (Y_{norm}). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 9/10 (Bonferroni: 8).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,778 [0,73; 0,82]	0,706 [0,51; 0,88]	0,288 [0,17; 0,44]	0,0001	0,53 [0,13; 1,66]	0,44	0,1041
X_2 (homología persistente)	0,870 [0,84; 0,90]	0,666 [0,48; 0,84]	0,367 [0,21; 0,46]	0,0019	0,99 [0,54; 2,18]	0,64	0,0173
$X_3^{(c)}$ (pesos iguales)	0,957 [0,93; 0,98]	0,772 [0,62; 0,90]	0,549 [0,47; 0,61]	<0,0001	1,26 [0,26; 3,85]	0,78	0,0036
$X_3^{(a)}$ (adaptativa)	0,948 [0,91; 0,98]	0,732 [0,48; 0,89]	0,504 [0,37; 0,60]	<0,0001	0,85 [0,64; 2,36]	0,80	0,0028
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,948 [0,91; 0,98]	0,745 [0,55; 0,94]	0,504 [0,37; 0,60]	<0,0001	0,85 [0,65; 2,33]	0,80	0,0028

SVHN

Rango de exactitud de prueba en el dominio: 26,0 puntos porcentuales en total (16,5 entre perceptrones multicapa y 7,2 entre redes convolucionales).

Tabla 11: SVHN, Población completa ($n=40$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 10/10 (Bonferroni: 10).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,928 [0,89; 0,95]	0,745 [0,60; 0,87]	0,470 [0,41; 0,54]	<0,0001	1,68 [0,55; 5,51]	0,80	0,0028
X_2 (homología persistente)	0,913 [0,88; 0,94]	0,747 [0,58; 0,87]	0,507 [0,44; 0,57]	<0,0001	2,31 [1,40; 4,02]	0,86	0,0013
$X_3^{(c)}$ (pesos iguales)	0,972 [0,94; 1,00]	0,762 [0,62; 0,88]	0,470 [0,40; 0,55]	<0,0001	0,71 [−0,19; 3,76]	0,80	0,0028
$X_3^{(a)}$ (adaptativa)	0,965 [0,94; 0,99]	0,803 [0,68; 0,91]	0,611 [0,53; 0,66]	<0,0001	3,86 [2,83; 6,40]	1,00	0,0002
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,965 [0,94; 0,99]	0,795 [0,66; 0,90]	0,611 [0,53; 0,66]	<0,0001	3,86 [2,83; 6,20]	1,00	0,0002

Tabla 12: SVHN, Solo perceptrones multicapa ($n=30$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 8/10 (Bonferroni: 4).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,875 [0,80; 0,93]	0,633 [0,39; 0,85]	0,188 [−0,03; 0,36]	0,4788	1,04 [0,00; 2,79]	0,63	0,0530
X_2 (homología persistente)	0,873 [0,82; 0,93]	0,724 [0,56; 0,86]	0,389 [0,29; 0,48]	0,0067	2,47 [1,61; 5,36]	0,92	0,0023
$X_3^{(c)}$ (pesos iguales)	0,958 [0,91; 0,99]	0,666 [0,44; 0,87]	0,345 [0,11; 0,48]	0,0003	1,39 [0,55; 2,94]	0,71	0,0262
$X_3^{(a)}$ (adaptativa)	0,938 [0,90; 0,97]	0,679 [0,44; 0,88]	0,413 [0,25; 0,54]	0,0003	1,54 [0,73; 3,08]	0,76	0,0175
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,938 [0,90; 0,97]	0,686 [0,46; 0,89]	0,413 [0,25; 0,54]	0,0003	1,54 [0,82; 3,13]	0,76	0,0175

Tabla 13: SVHN, Solo redes convolucionales ($n=10$). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 0/10 (Bonferroni: 0).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	1,000 [1,00; 1,00]	0,785 [0,33; 1,00]	0,491 [0,18; 0,69]	0,0286	n. d.*	0,00	1,0000
X_2 (homología persistente)	1,000 [1,00; 1,00]	0,720 [0,32; 1,00]	0,284 [−0,09; 0,53]	0,2164	n. d.*	0,50	0,6667
$X_3^{(c)}$ (pesos iguales)	0,981 [0,83; 1,00]	0,792 [0,33; 1,00]	0,440 [0,11; 0,65]	0,0726	n. d.*	1,00	0,3333
$X_3^{(a)}$ (adaptativa)	1,000 [1,00; 1,00]	0,763 [0,33; 1,00]	0,425 [−0,00; 0,64]	0,0466	n. d.*	1,00	0,3333
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	1,000 [1,00; 1,00]	0,755 [0,33; 1,00]	0,425 [−0,00; 0,64]	0,0466	n. d.*	1,00	0,3333

Tabla 14: SVHN, Exactitud normalizada por tipo de red (Y_{norm}). Media [IC 95 %] sobre la validación cruzada repetida (AUC familiar y τ) y sobre 300 remuestreos bootstrap (AUC por pares); d de Cohen y prueba de Mann–Whitney entre familias extremas. Contrastes significativos tras Benjamini–Hochberg: 8/10 (Bonferroni: 6).

Descriptor	AUC familiar	AUC por pares	τ de Kendall	p_τ	d de Cohen	r_{MW}	p_{MW}
X_1 (grafo funcional)	0,928 [0,89; 0,95]	0,642 [0,47; 0,81]	0,012 [−0,19; 0,19]	0,2838	0,59 [−0,27; 1,86]	0,36	0,1859
X_2 (homología persistente)	0,913 [0,88; 0,94]	0,718 [0,54; 0,85]	0,371 [0,27; 0,46]	0,0002	1,59 [0,74; 3,06]	0,74	0,0058
$X_3^{(c)}$ (pesos iguales)	0,972 [0,94; 1,00]	0,667 [0,48; 0,84]	0,373 [0,26; 0,48]	0,0064	1,35 [0,39; 3,34]	0,80	0,0028
$X_3^{(a)}$ (adaptativa)	0,963 [0,93; 0,98]	0,683 [0,51; 0,83]	0,401 [0,29; 0,50]	<0,0001	1,46 [0,59; 3,03]	0,78	0,0036
$X_3^{(r)}$ (adaptativa, ponderación por rangos)	0,963 [0,93; 0,98]	0,686 [0,47; 0,82]	0,401 [0,29; 0,50]	<0,0001	1,46 [0,60; 3,17]	0,78	0,0036

Referencias

- Ballester, R., Arnal Clemente, X., Casacuberta, C., Madadi, M., Corneanu, C. A. y Escalera, S. (2024). Predicting the generalization gap in neural networks using topological data analysis. *Neurocomputing*, 596, 127787.
- Bauer, U. (2021). Ripser: efficient computation of Vietoris–Rips persistence barcodes. *Journal of Applied and Computational Topology*, 5, 391–423.

- Chazal, F., de Silva, V. y Oudot, S. (2014). Persistence stability for geometric complexes. *Geometriae Dedicata*, 173, 193–214.
- Cohen-Steiner, D., Edelsbrunner, H. y Harer, J. (2007). Stability of persistence diagrams. *Discrete & Computational Geometry*, 37, 103–120.
- Edelsbrunner, H., Letscher, D. y Zomorodian, A. (2002). Topological persistence and simplification. *Discrete & Computational Geometry*, 28, 511–533.
- Zhang, B., Dong, Z., Zhang, J. y Lin, H. (2023). Functional network: A novel framework for interpretability of deep neural networks. *Neurocomputing*, 519, 94–103.